

적대적 생성 신경망(GAN)을 활용한 오버샘플링에 관한 연구

저자 (Authors)	안철휘, 이모세, 안현철
출처 (Source)	한국지능정보시스템학회 학술대회논문집 , 2018.6, 76-79 (4 pages)
발행처 (Publisher)	한국지능정보시스템학회 Korea Intelligent Information Systems Society
URL	http://www.dbpia.co.kr/Article/NODE07453160
APA Style	안철휘, 이모세, 안현철 (2018). 적대적 생성 신경망(GAN)을 활용한 오버샘플링에 관한 연구. 한국지능정보시스템학회 학술대회논문집, 76-79.
이용정보 (Accessed)	국민대학교 1.209.174.*** 2018/09/20 13:56 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독 계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

적대적 생성 신경망(GAN)을 활용한 오버샘플링에 관한 연구

안철휘

국민대학교

비즈니스 IT 전문대학원

7089ach@kookmin.ac.kr

이모세

국민대학교

비즈니스 IT 전문대학원

lms0417@kookmin.ac.kr

안현철

국민대학교

비즈니스 IT 전문대학원

hcahn@kookmin.ac.kr

Abstract - 적대적 생성 신경망(Generative Adversarial Network, GAN)은 서로 대립하여 데이터를 생성해내는 딥러닝(deep learning) 알고리즘 중 하나이다. GAN은 크게 데이터를 생성해내는 Generator 모델과 생성된 데이터를 판별하는 Discriminator 모델의 두 가지 모델로 구성되어 있다. 이들은 서로 대립하는 관계 속에서, 상호작용을 통해 성능을 조금씩 개선해 학습하여, 실제 데이터와 유사한 데이터를 새롭게 생성한다. 본 논문에서는 서로 대립하여 데이터를 생성해 내는 GAN 알고리즘을 부도예측을 위한 데이터에 적용하여, 불균형 데이터 문제를 극복하는 방안을 제시한다.

Key Terms - Bankruptcy, Data imbalance, Deep learning, Generative adversarial network, Over sampling.


I. 서론

딥러닝(deep learning)의 시초인 인공신경망(artificial neural networks)은 1980 년대에 처음으로 제안 되면서 1990 년대까지 활발한 연구가 진행되었다. 그렇지만 당시 학습용으로 쓰일 데이터의 부족과 과적합화 문제, 컴퓨터 성능의 한계로 인해 실제 현실에서 응용화 하기에는 많은 어려움이 있었고, 결국 침체기를 맞았다.

그러나 2010 년에 들어서면서 이미지, 음성과 같은 데이터가 축적되고 음성인식과 이미지 인식에 활용할 알고리즘으로 인공신경망이 다시 주목을 받기 시작하였다. 그리고 결국 2016 년 ‘알파고’의 등장 이후로 인공신경망에 대한 인식이 크게 바뀌었다. 먼저 컴퓨터 성능이 빠른 속도로 발전하면서, 특히 GPU(Graphics Processing Unit)에 의해 엄청난 데이터의 양을 학습하는 것이 가능하게 되었다. 이는 1990 년대

당시 컴퓨터 성능의 한계점을 극복하게 된 것이다. 이제는 1 개층의 은닉층을 n 개층으로 늘려 데이터에 대한 더욱 깊은 학습이 가능해졌다. 그 결과 DNN(Deep neural network)을 시작으로 이미지 데이터 분석에 강한 CNN(Convolutional neural network)과 시계열 데이터 분석에 강한 RNN(Recurrent neural network) 알고리즘 등이 등장하게 되었다. 현재 학계에서는 딥러닝을 중심으로 많은 연구 활동이 이어지고 있으며, 업계에서도 딥러닝 기반 기계학습 알고리즘들을 다양한 목적으로 적용하고 있다.


위에서 소개한 알고리즘들이 데이터를 분류, 예측, 인식 등에 활용되었다면, GAN(Generative Adversarial Network)은 데이터를 생성하는 점에서 다른 딥러닝 알고리즘들과 큰 차이점이 있다. 2014 년도에 Ian Goodfellow 가 제안한 GAN은 데이터를 새롭게 생성하는 Generator 모델과 생성된 데이터를 실제 데이터와 구분하여 판별하는 Discriminator 모델로 구성되어 있다. 이들은 서로 상호작용을 통해 실제 데이터와 유사한 데이터를 생성해낸다. Generator 모델에서 학습이 진행될수록, Discriminator 모델은 지속해서 생성되는 가짜데이터를 통해 데이터의 변형에 대한 강건성을 갖게 된다(Goodfellow et al., 2014).



<그림 1> GAN 프로세스

<그림 1>은 GAN 이 학습을 통해 실제 데이터와 유사한 데이터를 새롭게 생성해내는 절차를 나타내고 있다. 검은 점선은 실제 데이터의 분포를 나타내며, 파란 점선은 데이터를 판별하는 Discriminator 분포, 녹색 실선은 데이터를 생성해내는 Generator 분포이다. 밑의 x 와 z 는 각각 도메인을 뜻하며, $z \rightarrow x$ 를 가리키는 화살표는 GAN 모델의 $x = G(z)$ mapping 을 뜻한다. 처음 학습을 시작할 때, Discriminator 와 Generator 의 분포가 서로 다를 수 있다. 이 때 Discriminator 가 실제 데이터와 Generator 가 생성한 데이터를 구별하기 위해 반복적인 학습을 진행하게 되면서 (d)로 갈수록 점차 분포가 근사하게 만들어지게 된다. 결국 Discriminator 는 실제 데이터와 생성된 데이터를 구별하지 못하는 Discriminator = 1/2 상태가 되고, Generator 모델은 실제 데이터와 유사한 데이터를 생성되는 것이다.


현재 GAN 알고리즘을 활용하여 선행된 연구로는 불균형 게임 데이터에 GAN 알고리즘을 적용하여 오버 샘플링 기법을 제시한 연구(홍승진 등, 2017)와 불균형 데이터의 효율적인 분류를 위해 GAN 에 기반한 오버 샘플링 기법을 제시한 연구(서상현 등, 2017)가 있다.



<그림 2> GAN 예시

첫 번째 연구에서는 불균형 게임 데이터를 GAN 알고리즘의 변형 모델인 Info GAN 을 활용하여, SMOTE(Synthetic Minority Over-sampling Technique)기법과 비교하는 연구를 진행하였다. 그리고 두 번째 연구에서는 GAN 을 불균형 대출상환 데이터에 적용하여 데이터 불균형 문제를 해결하는 연구를 진행하였다. 이 두 연구에서는 GAN 을 활용하여, 불균형 데이터의 문제를 해결하고자 하는 공통점이 있다. 이에 본 연구에서는 또 다른 대표적인 불균형 데이터 중 하나인 기업 부도 데이터를 표본추출기법인 Under, Over, SMOTE, Rose, 기법과 GAN 알고리즘에 적용하여 GAN 의 성능을 확인하고자 한다.

2. GAN (Generative Adversarial Network)



<그림 3> GAN ALGORITHM 구조

<그림 3>은 GAN 이 학습을 통해 데이터를 생성하여 판별하는 알고리즘 구조이다. 앞서 설명했듯이, GAN 은 기본적으로 두 개의 모델이 적대적으로 구성되어 있다. 먼저 새롭게 데이터를 생성하는 역할을 하는 'G'(Generator)와 이를 판별하기 위한 역할인 'D'(Discriminator)가 여기에 해당한다. 모델 'G' 에서 임의의 분포로 생성한 데이터는 원본 데이터와 함께 모델 'D' 에 제공된다. 모델 'D' 는 제공받은 데이터가 원본 데이터인지, 위조 데이터인지 판단하게 된다. 즉, 데이터를 판별하는 모델 'D' 는 원본 데이터와 위조 데이터를 판별하기 위해 학습을 진행하고, 데이터를 생성하는 모델 'G' 는 모델 'D' 를 보다 잘 속이기 위해 학습을 진행하게 되며, 결국 이 두 모델들은 데이터의 생성과 판별 두 개의 상호작용을 통해 각자의 성능을 발전시키게 된다. 이를 수학적으로 표현하면 아래 <그림 4>와 같이 표현한다.

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log (1 - D(G(z)))]$$

<그림 4> GAN 수식

위 식에서 p_{data} 는 원본 데이터를 뜻하며, $P(z)$ 는 데이터를 생성하기 위한 모델 'D'의 Random noise 를 뜻한다. 모델 'D'는 생성된 데이터는 원본 데이터인 p_{data} 와 확률 분포상에서 근사하게 같아지도록 학습을 진행하여 데이터를 생성하는데, 이를 판별하는 모델 'G'는 원본 데이터에서 제공받았을 확률을 계산하게 된다. 이때 모델 'G'는 명확하게 분류를 하기위해 엔트로피값을 최대값인 1 방향으로 학습하게 되고 모델 'D'는 모델 'G'가 원본 데이터와 위조 데이터를 구별하지 못하는 상태인 최소값 0 이 되도록 학습을 진행하게 된다.

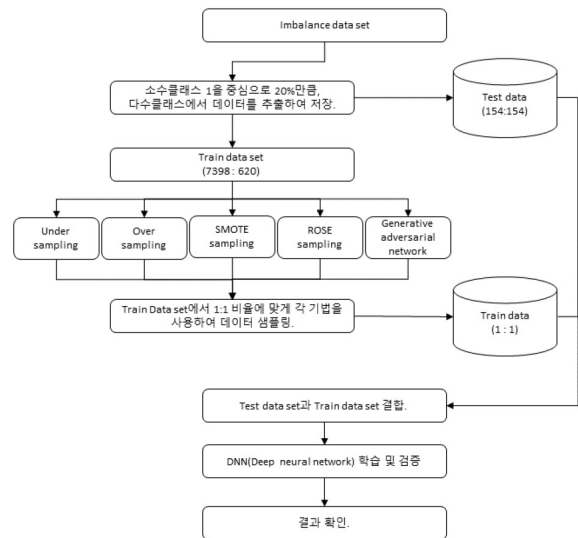
보다 구체적인 GAN의 학습 과정은 다음과 같다.

1 단계: 모델 'D'가 데이터 판별을 할 수 있도록 원본 데이터를 모델 'D'에 학습한다.

2 단계: 모델 'D'에서 실제 데이터에 대해 학습이 진행된 후, 모델 'G'는 입력을 업데이트 하며 모델 'D'와 모델 'G'는 서로 학습을 진행한다.

3 단계: 학습이 진행될수록 모델 'G'는 위조 데이터를 실제 데이터와 유사하게 생성하고, 모델 'D'는 이를 구분하지 못하는 확률을 가진 상태($P_d=0.5$)가 된다.

결국 위와 같은 과정을 계속 반복할수록 <그림 4> 수식에 명시되어 있는 P_{data} 와 P_g 의 성능이 발전하게 되고, 결국 원본 데이터의 분포에 유사한 데이터를 생성해낸다.



<그림 4> 실험 모델 구조

III. 실험 모형

<표 1> 원본 데이터 SET

Division	Data set	Data Ratio
1	774	9.3%
0	7,552	90.7%
Total	8,326	100%

제안하는 연구를 진행하기 앞서 활용할 데이터는 한국 기업 비외감 기업에 대한 부도예측 데이터인 H' 은행 데이터를 활용할 계획이다. 본 데이터 세트의 데이터 수는 총 8,326 개이고, 그 중 774 건(9.3%)이 부도사례, 나머지 7,552 건(90.7%)이 비부도사례로 구성되어 있다. 본 연구에 사용될 데이터의 독립변수는 총 9 개의 재무비율 변수들이며, 종속변수로는 부도와 비부도 상태를 나타내는 이진 변수를 사용하였다. 실험 과정은 다음의 <그림 4>와 같다.

1 단계: 불균형한 데이터 세트에서 소수 클래스를 중심으로 20% 개수 만큼 데이터를 추출하고, 다수 클래스에서도 이와 같은 개수만큼 추출하여 1:1 의 비율을 가진 검증용 데이터세트로 저장한다.

2 단계: 학습용 데이터세트의 소수 클래스의 데이터 1을 GAN을 포함한 각 5가지 샘플링 기법을 통해 1:1 비율을 가진 학습용 데이터 세트로 저장한다.

3 단계: 검증용 데이터 세트와 학습용 데이터 세트를 결합한다.

4 단계: 결합한 데이터 세트를 DNN에 적용하여 예측 정확도에 따른 결과를 확인한다.

VI. 결론

본 논문에서는 데이터 불균형 문제를 해결하는 새로운 방안으로 대표적인 딥 러닝 알고리즘 중 하나인 GAN을 기업부도예측모형에 적용하는 연구를 제안하였다. 향후 설계한 연구 모델을 바탕으로 연구를 수행하여 이에 따른 결과와 성능을 확인할 계획이다.

V. 참고문헌

I. Goodfellow, J. Pouget-Abadie, M. Mirze, B. Xu, D. WardeFarley, S. Ozair, A. Courville and Y. Bengio "Generative Adversarial Nets," Proc. Advances in Neural Information Processing Systems, (2014), 2672~2680.

서상현, 전용진, 이종수, 정호재, 김준태, "불균형 빅데이터의 효율적인 분류를 위한 생산적 적대신경망 기반 오버 샘플링 기법," 한국정보과학회 2017 한국 소프트웨어 종합학술대회 논문집, 2017, 1030~1032

홍승진, 이상광, 양성일, “불균형 게임데이터 문제해결을 위한 Generative Adversarial Network 기반 오버 샘플링 기법,” 대한전자공학회 하계종합학술대회, 2017, 1227~1228.